# RE-ALIGN:Aligning Vision Language Models via Retrieval-Augmented Direct Preference Optimization

**发表**：EMNLP 2025 主会

https://github.com/taco-group/Re-Align

## 摘要

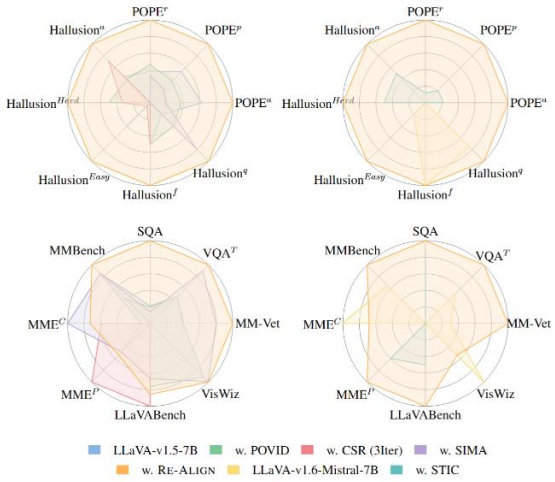
大型视觉语言模型（VLMs）通过融合视觉模态，拓展了单模态大语言模型（LLMs）的能力边界与应用范围，在各类现实场景中催生出变革性的跨模态应用。尽管视觉语言模型性能亮眼，但它很容易产生严重的幻觉问题，突出表现为跨模态信息不一致。受人类反馈强化学习（RLHF）在大语言模型对齐任务上取得成功的启发，现有研究大多基于精心构建的数据集，采用直接偏好优化（DPO）来缓解上述幻觉问题。然而，这类方法往往采用简单粗暴的方式引入偏好信号，忽视了视觉信息在对齐过程中的关键作用。

本文提出 **RE-ALIGN** 这一全新对齐框架：利用图像检索构建双重偏好数据集，同时融合文本与视觉两类偏好信号；进一步提出 **rDPO**，作为标准直接偏好优化算法的扩展，在微调阶段额外增加一项视觉偏好优化目标。

实验结果表明：RE-ALIGN 相较已有方法，不仅能够更好地缓解模型幻觉，还可以在通用视觉问答（VQA）任务上带来可观的性能提升。此外，RE-ALIGN 在不同参数量、不同架构的视觉语言模型上均表现出良好鲁棒性与可扩展性。本研究为多模态大语言模型的对齐工作迈出重要一步，为实现更加可靠、高效的跨模态应用奠定基础。

## 解决了一个什么下游任务

**抑制 VLM 的跨模态不一致型幻觉**——模型生成的文本与图像对不上，编造图中不存在的物体、说错属性、讲反物体关系。它被归入 alignment 问题而非单纯事实性问题。评测分两侧：幻觉侧用 POPE 与 HallusionBench；通用能力侧铺开 ScienceQA、TextVQA、MM-Vet、VisWiz、LLaVABench、MME、MMBench 七个基准，用来检验对齐是否付出了能力代价。




## 传统做法都是怎么解决的

主线是把 LLM 的 RLHF 迁移到多模态。相比 PPO，DPO 计算高效、易于调参。给定偏好数据 $\mathcal{D} = \{(x, v, y_w, y_l)\}$（$x$ 指令、$v$ 图像、$y_w$ 好回复、$y_l$ 差回复）：

$$\mathcal{L}_{\text{DPO}} = -\mathbb{E}\left[\log\sigma\left(\beta\log\frac{\pi_\theta(y_w|x,v)}{\pi_0(y_w|x,v)} - \beta\log\frac{\pi_\theta(y_l|x,v)}{\pi_0(y_l|x,v)}\right)\right]$$

其中 $\pi_\theta$ 为待优化策略，$\pi_0$ 为 SFT 后的初始模型，$\beta$ 控制偏离程度。它拉大两个回复相对于初始模型的对数概率差。

重心因此落在**偏好数据从哪来**，现有工作分两类。一类**造 rejected**：扰动真值回复或破坏视觉输入与嵌入。可扩展，但人为破坏出的错误生硬、不自然，与模型真实幻觉分布相差甚远。另一类**造 chosen**：请人或强模型精炼回复。信号可靠，但成本极高、难规模化。二者形成“便宜但失真、可靠但昂贵”的两难。

更隐蔽的问题在目标本身：上述做法里偏好对都是在**同一张图** $v$ 下比较的文本，图像只是被固定的条件，从未成为被比较的对象。已有研究指出直接套 DPO 会让模型过度迎合语言偏好，反而增加幻觉。mDPO 试图补救，用随机裁剪图 $v_c$ 作负条件构造 $\mathcal{L}_{\text{CoDPO}}$，但裁剪图语义残缺、与指令无关，对比信号偏弱且缺乏语义意义。

## 问题描述

**其一，偏好数据的可信度。** 造 rejected 的现有方式是“brute-force”暴力注入：往真值里塞错误、把图像或嵌入搞坏，得到的都不是模型自然推理中会犯的错。好比训练里的错误答案全是人为打乱的病句，模型学到的只是“识别病句”，而不是“识别自己看错图”。可模型自己犯的错，该怎么被稳定、可控地诱导出来并判定为错？这是作者要解的结。

**其二，视觉信号在对齐中的缺席。** 在标准 DPO 里，图像 $v$ 对 $y_w$ 和 $y_l$ 是同一条件，其对数概率项在优化中被抵消，梯度只反映文本侧的相对偏好。结果是模型学会迎合语言风格，却没被教导“图像换掉时这个回答就不该再成立”。作者据此主张：**对齐必须在视觉维度上也比较**——模型不仅要知道哪个回答更好，还要知道哪张图支撑这个回答。

两条合起来是一个被割裂处理的结构性缺口：数据侧缺既自然又可控、既便宜又可靠的幻觉生成机制；目标侧缺把视觉条件纳入比较的优化项。而作者的解法在两侧高度自洽——**用检索来的相似图诱导模型犯错，同时解决了“自然的 rejected 从哪来”和“视觉对比项用哪张图”**。这也正是它优于 mDPO 随机裁剪之处。

## 具体方法

整体思想是“**用相似图骗模型犯错，再把这张图作为负条件教它别犯**”，分两个阶段。

**阶段一，三步构造偏好数据。** 第一步**策略性掩盖**：用 GPT-4o mini 把 chosen 回复 $y_w$ 中涉及物体、属性、逻辑关系的片段掩盖，得 $y_m$。

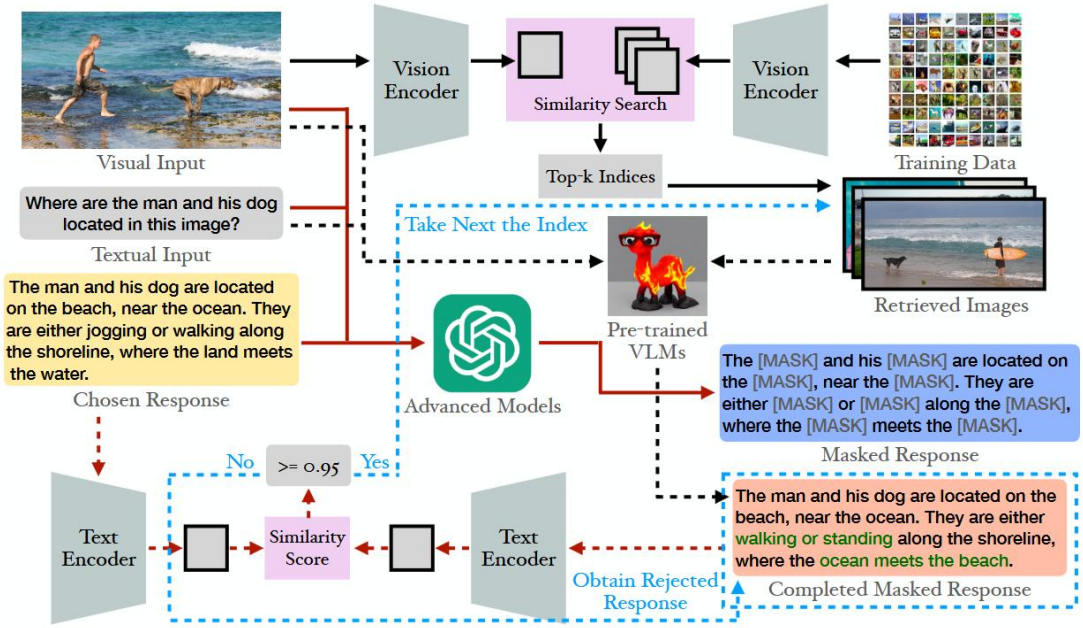
第二步**图像检索**：用 VLM 视觉编码器把训练集全部图像编码成向量建库 $\mathcal{K}$，对输入图按余弦相似度取 top-$k$

第三步**诱导幻觉**：把 $y_m$、指令 $x$ 与检索图 $v_l$ 一起喂给**待训练的、本身容易幻觉的 VLM**，让它补全掩码得 $y_c$——模型看到的是相似但不同的图，补全自然“张冠李戴”。再用 SentenceTransformer 编码 $y_w$ 与 $y_c$。$\tau$ 是“错误幅度”的闸门，消融显示 0.95 是幻觉抑制与通用能力的最佳权衡。最终得到比标准 DPO 多一个检索图 $v_l$ 的**双重偏好数据集** $\mathcal{D} = \{x, v, v_l, y_w, y_l\}$。

**阶段二，rDPO 目标。** 第一项是标准 DPO，在同一张原图 $v$ 下比较 $y_w$ 与 $y_l$，管文本侧偏好。第二项是新增的视觉偏好项：

$$\mathcal{L}_{\text{vDPO}} = -\mathbb{E}\left[\log\sigma\left(\beta\log\frac{\pi_\theta(y_w|x,v)}{\pi_0(y_w|x,v)} - \beta\log\frac{\pi_\theta(y_w|x,v_l)}{\pi_0(y_w|x,v_l)}\right)\right]$$

注意它比较的**不是两个不同回复，而是同一个 $y_w$ 在两种视觉条件下的相对似然**：模型看到原图 $v$ 时对这条正确回答的置信度，应显著高于看到检索图 $v_l$ 时。换言之，它在教模型“你的回答必须由眼前这张图支撑，换一张哪怕很像的图，这个回答就不该再被轻易说出”。最终目标 $\mathcal{L}_{\text{rDPO}} = \mathcal{L}_{\text{DPO}} + \mathcal{L}_{\text{vDPO}}$。




## 实验结论

从 LLaVA-Instruct-150K 采样 11k 张图，GPT-4o mini 生成问答对，CLIP-ViT-L/14 建库，基座为 LLaVA-v1.5-7B 与 v1.6-Mistral-7B，微调 1 epoch，评测温度 0。POPE 上 LLaVA-v1.5-7B 由 88.14/87.23/85.10 升至 88.65/87.43/85.16；13B 由 88.07/87.53/85.60 升至 90.03/89.20/86.20，random 档提高约 1.96 个百分点，而对比方法增益普遍在 0.3 以内（HSA-DPO 在 13B 上甚至下滑 3 个点）。HallusionBench 图理解子集 41.76 升至 45.52。通用能力上 ScienceQA 66.02 升至 68.10，**八个通用基准平均排名由 3.875 跃升至 1.375**，说明没有用“变保守”换幻觉指标。在统一多模态模型 Janus-Pro 上同样有效，最小的 Janus-Pro-1B 增益最大。