Representation Potentials of Foundation Models for Multimodal Alignment: A Survey

发表：EMNLP 2025 主会
资源库：https://github.com/Jianglin954/Representation-Alignment-Survey

摘要

基础模型通过在多样化数据上开展大规模预训练，习得具备高度迁移性的表征。越来越多的研究表明：即便模型架构、模态各不相同，它们学到的表征仍存在显著的相似性。

在本篇综述中，我们探究基础模型的**表征潜能**。该概念被定义为：模型所学表征的一种内在能力 —— 既能够在单一模态内捕获任务专属信息，又可以为跨模态的对齐与统一提供可迁移的基础。

本文首先梳理具有代表性的基础模型，以及可用于量化对齐效果的关键指标；随后整合来自视觉、语言、语音、多模态以及神经科学领域的实证研究证据。现有证据表明，基础模型的表征空间普遍呈现出结构规律性与语义一致性，使其非常适合用于跨模态迁移与跨模态对齐。

我们进一步分析促成表征潜能的关键影响因素，探讨尚未解决的研究问题，并指出该领域现存的潜在挑战。

解决了一个什么“下游任务”

本文是综述回答一个科学问题：**单模态基础模型学到的表征，是否天然具备跨模态对齐的潜力**。作者造了一个术语 **representation potentials（表征潜力）**，定义为：**表征在单一模态内捕获任务特定信息的同时，还能为跨模态对齐与统一提供可迁移基座的潜在能力。**这个定义有两层：单模态内要够用，跨模态要可迁移。

其重要性在于一个隐含推论：如果不同模态、不同架构的模型在不做显式对齐训练的情况下也会**自然趋同**到共享的表征结构，那它们可能已逼近“模态无关的抽象”。

传统做法

历史上是两条并行却长期割裂的线索。

工程侧的显式对齐：用配对数据加对齐目标把两个模态“拉”到一起。训练目标通常是对比对齐、跨模态重建、掩码建模与指令微调四类手段的组合。但默认前提是**对齐必须靠显式训练获得**，不同模态表征在自然状态下是分离的。

分析侧的表示相似性研究：旨在衡量网络表征相似度，诞生 CKA、SVCCA、MNN 等分析工具，已有诸多结论：卷积滤波器可与 HOG 特征互换；独立训练网络存在功能重叠神经元；模型越宽表征相似度越高；自监督 ViT 注意力模式趋于一致。但相关研究分散于各子领域：视觉用 SVCCA 分析 CNN/ViT，NLP 用 CKA 分析 Transformer，语音聚焦信息涌现层级，各社区缺少互通，未从跨模态对齐潜力角度整合证据。

作者指出其中的结构性缺口：工程界专注对齐实现，很少探究对齐上限与模型的天然基础；分析界虽有大量表征趋同的实证，但未形成系统论证。同时领域缺少统一度量标准，论文所用指标、网络层、数据集各不相同，结论难以横向对比。

问题提出

核心主张是：**基础模型的表征并非孤立地强大，而是会在架构、训练目标乃至模态之间呈现显著相似性**。若它们天然收敛到共享表征结构，则可能已逼近模态无关的抽象，**即便没有经过显式对齐训练**。这把“对齐”从纯工程技巧重新定位为有理论根基的现象：显式对齐训练或许只是在“加速”或“校准”一个本就存在的趋同趋势。

在此视角下，作者揭示三个此前未被妥善回答的问题。

1. **证据碎片化**：视觉、语言、神经科学已有大量表征趋同实证，但分散在各领域，缺少系统性解读，工程界无法判断对齐模块是利用天然潜力，还是对抗模态固有差异。
2. **度量标准缺失**：CKA、CCA、MNN 各有侧重，结果可能冲突；高对齐分数未必代表真实语义对齐。反例表明：仅初始化不同也会带来表征差异；指标可发现性能体现不出的内部差别；高相似度仅代表特征可被相似解码。
3. **破除完全对齐的误区**：视觉、语言等模态感知信息各有侧重，部分信息为模态独有。表征无法、也无需完全一致，对齐追求部分共享、互补的抽象，不应一味追求缩小模态鸿沟。

具体方法

问题设定：给定两组表征 $X \in \mathbb{R}^{n \times d_1}$、$Y \in \mathbb{R}^{n \times d_2}$，判断二者是否编码同一信息；允许旋转、缩放、仿射等可容许变换，只要求**结构等价**，而非逐元素相等。

CKA：比较中心化后的 Gram 矩阵 $K = XX^\top$、$L = YY^\top$，本质是二者在希尔伯特–施密特空间中夹角的余弦，取值 $[0,1]$，1 为完美对齐；对各向同性缩放与正交变换不变，只关心样本间的相对关系。

$$\mathrm{CKA}(X,Y) = \frac{\mathrm{HSIC}(K,L)}{\sqrt{\mathrm{HSIC}(K,K)\,\mathrm{HSIC}(L,L)}}, \qquad \mathrm{HSIC}(K,L) = \mathrm{tr}(\widetilde{K}\widetilde{L})$$

CCA / SVCCA（适用：两个本身结构比较接近的表征空间做对比）：求一组线性投影使投影后相关性最大；SVCCA 先做 SVD 压缩到主子空间以滤噪，再做 CCA。二者对仿射变换不变，SVCCA 额外抗噪。

$$\max_{a,b} \rho = \frac{a^\top C_{XY} b}{\sqrt{a^\top C_{XX} a}\,\sqrt{b^\top C_{YY} b}}$$

MNN：统计双向互为 k 近邻的样本比例，属**局部度量**，双向要求用于滤除高维空间中的单向假阳性。

指标	全局 / 局部	核心特点
CCA	全局	寻找线性投影最大化相关；仿射不变；对噪声敏感
SVCCA	全局	SVD 降噪 + CCA；仿射不变，抗噪声；适合相近表征空间对比
MNN	局部	双向 k 近邻统计；过滤高维假阳性，看样本级匹配

五领域证据：视觉——不同初始化或架构的模型中间层可用单个仿射层缝合且性能几乎无损，跨架构稳定出现 Rosetta neurons，相似度随规模与性能上升；**语言**——存在跨模型通用神经元，探针与引导向量经仿射映射可从小模型迁移到大模型，Transformer 与 Mamba 亦共享大量内部电路；**语音**——训练目标的影响大于架构选择；**神经科学**——模型间的表征一致性可预测其与大脑的对齐程度。

驱动因素：

驱动因素	核心含义
规模	缩放定律：规模上涨，性能、表征相似度同步提高

驱动因素	核心含义
架构	Transformer 利于泛化；但表征收敛受架构、训练目标约束，不会无条件趋同
训练范式	自监督学习更容易产出泛化能力强的表征
指令多样性	指令种类丰富度 > 单指令样本数量，对表征潜力影响更大

核心结论与开放问题

三个层面均有强证据：视觉侧不同架构、目标、数据集的模型发展出兼容理解且相似度随规模上升；语言侧出现跨模型通用神经元、可迁移探针与引导向量；神经科学侧模型间一致性可**预测**其与大脑的对齐程度。但完全收敛既不可能也不必要。

开放问题中，除度量标准争议外，作者强调**模态差异带来的根本限制**，并给出一个严肃保留：**数据偏见与社会技术语境**——训练数据来自互联网、继承了人类偏见与文化规范，观察到的“一致性”究竟反映普遍认知结构，还是特定训练范式的产物，目前无法排除。