# SEA 用于 MLLMs 中的词元级图文融合

**论文**：SEA: Supervised Embedding Alignment for Token-Level Image-Text Fusion in MLLMs

## 摘要

多模态大语言模型（MLLM）通过整合视觉和文本输入展示了卓越的能力，但模态对齐仍然是最具挑战性的方面之一。当前的 MLLM 通常依赖简单的适配器架构和预训练方法，在图像级监督的指导下将视觉编码器与大语言模型（LLM）桥接。我们发现这种范式通常导致模态间次优对齐，显著限制了 LLM 正确解释和推理视觉特征的能力，特别是对于较小的语言模型。这种局限性降低了整体性能——特别是对于容量限制更明显且适应能力有限的较小语言模型。

为了解决这个根本性局限，我们提出了监督嵌入对齐（SEA），这是一种 token 级监督对齐方法，能够在预训练期间实现更精确的视觉 - 文本对齐。SEA 引入了最小的计算开销，同时保留了语言能力并显著提高了跨模态理解。我们的综合分析揭示了 adapter 在多模态集成中作用的关键见解，并且广泛的实验表明 SEA 持续改善了不同模型尺寸的性能，其中较小的模型受益最大（Gemma-2B 的平均性能提升为 7.61%）。这项工作为未来多模态系统开发更有效的对齐策略奠定了基础。

## 理解核心问题

多模态大型语言模型（MLLM）结合了视觉和语言理解能力，但它们面临一个根本性挑战：如何正确对齐视觉和文本信息。

当前的 MLLM 通常采用两阶段方法——预训练后进行指令微调——其中适配器 adapter 将视觉特征映射到语言模型的输入空间。然而，这一过程存在本文旨在解决的关键局限性。

现有方法的主要问题包括**语义失真**（即视觉 token 在适配过程中失去其预期含义）以及视觉和文本模态之间存在显著的**表征鸿沟**。这些问题迫使语言模型去补偿未对齐的输入，而不是有效利用其预训练能力。

## SEA 方法论

监督嵌入对齐（SEA）引入了一种 token 级监督范式，从根本上改变了预训练期间视觉和文本信息的整合方式。SEA 不依赖粗粒度的图像级监督，而是为单个视觉 token 提供精确的语义指导。

该方法通过几个关键步骤运作：

**语义标签提取**：SEA 利用预训练的视觉－语言模型（CLIP）为每个视觉补丁提取语义标签。对于每个视觉补丁，系统会计算其与来自综合词汇表中大约 400 万个单词的相似度得分。前 10 个最相似的单词成为该补丁的语义标签，从而创建了连续的语义表示，而非硬性的类别分配。

**Token 级对齐**：核心创新在于对比学习目标，它在语言模型的嵌入空间中将视觉 token 与其对应的语义标签对齐。对齐损失公式如下：

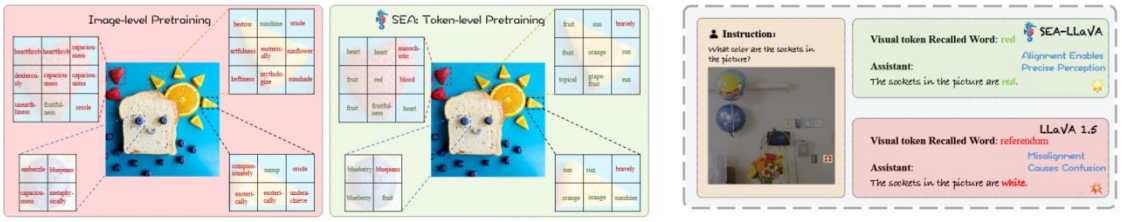
$$\mathcal{L}_a = \text{ContrastiveLoss}(x_v, t)$$

其中，$x_v$ 表示经过 adapter 处理的视觉 token，$t$ 表示采样语义标签的组成 token 的平均嵌入。（grass 被拆成 2 个 token，取两个子 token 的嵌入，相加除以 2，得到 t，代表草在 LLM 内心向量空间的位置。）对于正样本让视觉 token$x_v$，尽量靠近目标向量$t$；

**训练整合**：最终的预训练损失结合了标准的自回归语言建模损失和对齐损失：

$$\mathcal{L} = \mathcal{L}_g + \lambda \cdot \mathcal{L}_a$$

这种方法确保视觉 token 被映射到语言模型嵌入空间中具有语义意义的区域，同时保持模型的文本生成能力。

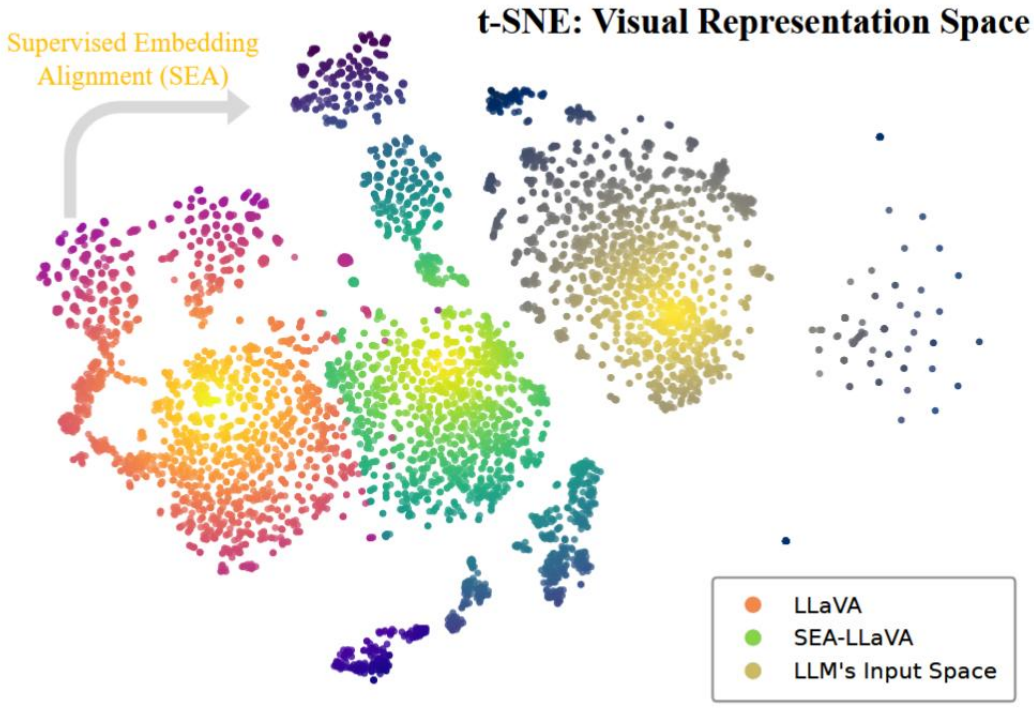



(a) Accurate representation alignment with SEA. (b) Improved visual perception enabled by SEA.

## 弥合表征鸿沟

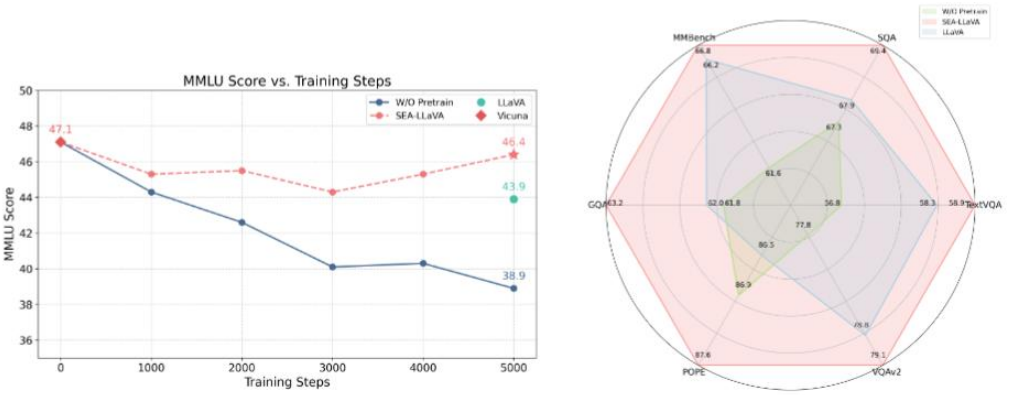
SEA 最重要的贡献之一是其弥合模态表征鸿沟的能力。传统方法通常会导致视觉 token 聚集在远离语言模型原生文本嵌入的位置，从而给大型语言模型（LLM）带来适配负担。

t-SNE 可视化展示了与传统方法相比，SEA 处理的视觉 token（彩色点）如何更自然地融入 LLM 的原生输入空间。这种改进的对齐减少了语言模型的计算负担，并保留了其预训练的语言能力。




## 实验结果与影响

实验验证表明 SEA 在多个维度上均有效。SEA-PRIME 模型在八个流行基准测试中始终优于现有基线，对于较小的语言模型，其性能提升尤其显著。例如，Gemma-2B 模型平均性能提升了 7.61%。




(a) MMLU with Finetuning (b) Results of Different Methods

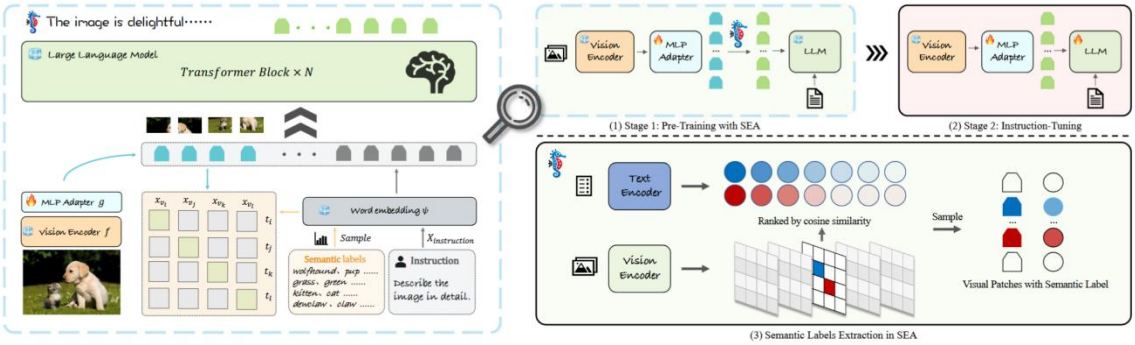
结果揭示了几个重要见解：

**可扩展性优势**：SEA 在从 2B 到 13B 参数的各种语言模型中表现出持续改进，其中在较小型模型中观察到最显著的增益。这表明 SEA 的精确对齐减少了通常为补偿未对齐视觉输入而所需的容量要求。

**语言能力保持**：与传统方法在多模态适应期间通常会降低语言模型性能不同，SEA 在整个训练过程中保持了更高的 MMLU 分数。这种语言能力的保持对于在增强视觉理解的同时维持模型的推理能力至关重要。

**细粒度视觉感知**：token 级监督实现了更准确的视觉 token 表示，从而在包括详细图像描述、对象识别和光学字符识别在内的各种感知任务中提高了性能。

## 技术架构与实现




SEA 框架无缝集成到现有 MLLM 架构中，无需额外的推理开销。训练管道保持标准的两阶段方法，但通过令牌级语义监督增强了预训练阶段。

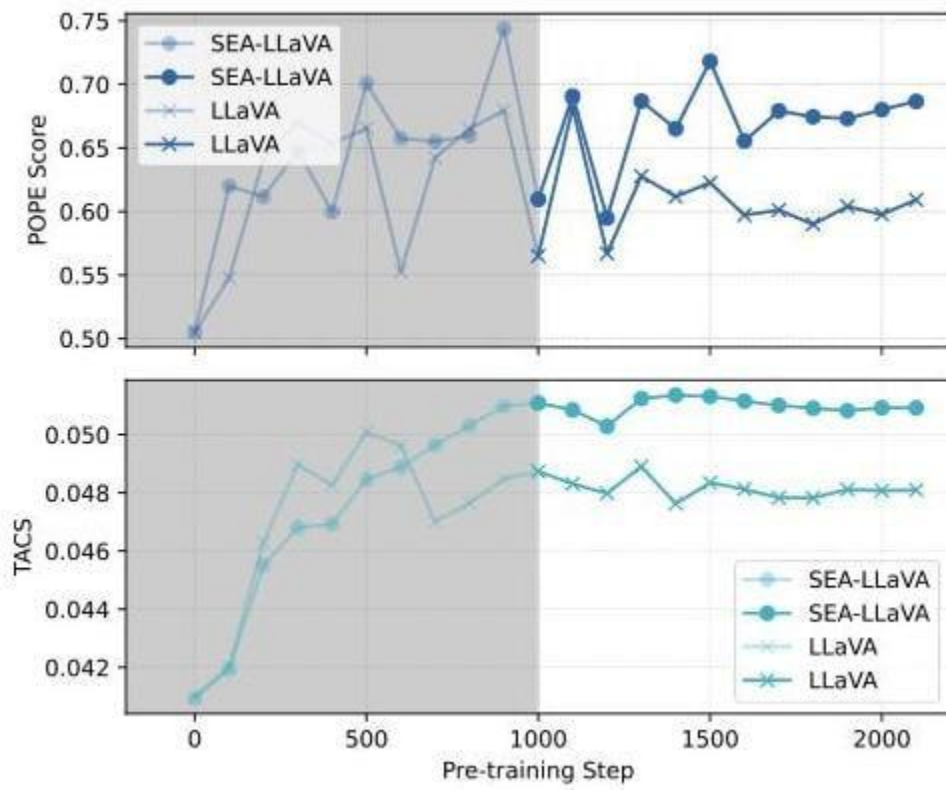
在预训练期间，SEA 采用了多项技术创新：

**相似度加权采样**：SEA 不使用硬标签，而是根据归一化相似度分数对语义标签进行采样，从而考虑了视觉语义的连续性。

**局部采样策略**：为了提高对比学习的有效性，SEA 采用 $2 \times 2$ 窗口采样方法，确保采样视觉补丁的多样性，同时避免过于相似的例子。

**交叉编码器迁移**：语义监督框架成功地将源自一个视觉编码器（CLIP）的标签迁移到增强其他编码器（如 DINOv2），展示了该方法的通用性。

## 性能分析与验证




令牌对齐一致性分数（TACS）的引入为衡量对齐质量提供了直接指标。训练曲线显示，与基线相比，SEA 始终获得更高的 TACS 分数，并且这种改进与事实基础任务（POPE 分数）上更好的性能相关。

实验结果涵盖了多个评估情境：

**基准性能**：即使使用较小的语言模型骨干，SEA-PRIME 模型也能取得有竞争力的结果，表明效率有所提高。在需要细粒度视觉理解的任务中，改进尤为显著。

**消融研究**：SEA 的鲁棒性在不同的语言模型大小和视觉编码器架构中得到证明，证实其优势不限于特定的模型配置。

**下游任务迁移**：SEA 提供的强大预训练基础使得在指令微调期间对视觉编码器进行后续微调时能实现更好的性能，这表明初始对齐与任务特定适应之间存在有益的协同作用。

## 意义与未来方向

SEA 通过解决令牌级别的跨模态对齐核心挑战，代表了多模态 AI 的根本性进步。这项工作具有几个重要意义：

**效率与可及性：**通过使较小的语言模型能够实现具有竞争力的多模态性能，SEA 使先进的多模态 AI 对资源受限的环境更易于访问且在计算上更可行。

**架构灵活性：**该框架跨不同视觉编码器迁移语义监督的能力为更模块化和适应性强的 MLLM 设计开辟了可能性。

**扩展的基础：**为视觉－语言整合建立的令牌级对齐范式提供了一个模板，该模板有潜力扩展到音频和视频等其他模态，从而有助于开发真正的通用多模态 AI 系统。

这项研究还提出了关于模态对齐和安全考量之间相互作用的重要问题，突出了在负责任的 AI 开发中未来需要深入研究的领域。通过提供一种更具原则性的多模态整合方法，SEA 为下一代高效且强大的多模态 AI 系统奠定了坚实的基础。